Étape 0 : Recherche scientifique

Prédiction du diabète à partir des données BRFSS (CDC)

Réalisé par : Mohammed Nezhari, Soufiane Ait ouchn et Abdelouafi Er-raqui
Encadré par : Pr. Zineb BOUSBAA

1. Introduction

Pour situer notre projet dans la littérature, nous avons recherché des articles scientifiques qui étudient la prédiction du diabète à partir des données du **Behavioral Risk Factor Surveillance System (BRFSS)**. Cette enquête téléphonique annuelle est réalisée par le CDC (Centers for Disease Control and Prevention) aux États-Unis. Nous avons privilégié les articles qui utilisent des **données accessibles en ligne**, en particulier le dataset Kaggle *Diabetes Health Indicators (BRFSS 2015)*, celui de notre projet. Pour chaque article, nous avons extrait les variables explicatives utilisées dans la partie expérimentale.

2. Articles sélectionnés

Article 1 : Xie et al. (2019)

Référence	Xie Z., Nikolayeva O., Luo J., Li D. *Building Risk Prediction Models for Type 2 Diabetes Using Machine Learning Techniques.* Preventing Chronic Disease, vol. 16, 2019.
Données	BRFSS 2014 (CDC), 138 146 personnes après nettoyage.
Variable cible	DIABETE3 : diabète (oui / non).
Variables explicatives (26)	GENHLTH, X_AGEG5YR, X_BMI5CAT, CHECKUP1, INCOME2, X_RACE, MSCODE, FLUSHOT6, EMPLOY1, SEX, MARITAL, X_EDUCAG, SLEPTIM1, CVDCRHD4, HLTHCVR1, MENTHLTH, CHCKIDNY, USEEQUIP, X_TOTINDA, ADDEPEV2, RENTHOM1, EXERANY2, BLIND, DECIDE, HLTHPLN1, _SMOKER3
Modèles	SVM, arbre de décision, régression logistique, Random Forest, réseau de neurones, Naive Bayes (rééquilibrage SMOTE).
Résultat	Réseau de neurones : AUC = 0,795 ; accuracy = 82,4 %.

Article 2 : Zhao (2023)

Référence	Zhao Z. *Research on the Predictive Accuracy of Diabetes based on the BRFSS Database.* Highlights in Science, Engineering and Technology, vol. 54, 2023.
Données	BRFSS 2015 (Kaggle), 253 680 personnes.
Variable cible	Diabetes_binary.
Variables explicatives (21)	HighBP, HighChol, CholCheck, BMI, Smoker, Stroke, HeartDiseaseorAttack, PhysActivity, Fruits, Veggies, HvyAlcoholConsump, AnyHealthcare, NoDocbcCost, GenHlth, MentHlth, PhysHlth, DiffWalk, Sex, Age, Education, Income
Méthodes	Boxplots, régression avec sélection pas à pas (critère AIC), test du chi-deux.
Résultat	Variables les plus influentes : BMI, GenHlth, HighBP, HighChol, Age.

Article 3 : Jafari Horestani & Owrang (2024)

Référence	Jafari Horestani F., Owrang O M.M. *Predicting Diabetes with Machine Learning Analysis of Income and Health Factors.* arXiv:2404.13260, 2024.
Données	BRFSS 2015 (Kaggle), fichier diabetes_012_health_indicators_BRFSS2015.csv, 253 680 personnes.
Variable cible	Diabetes_012 (0 = non diabétique, 1 = prédiabète, 2 = diabète).
Variables explicatives	Départ : les 21 variables du dataset. **Modèle 1** (après sélection par Lasso, Random Forest et RFE) : 6 variables : HighBP, HighChol, CholCheck, Smoker, HvyAlcoholConsump, BMI. **Modèle 2** : Income seul.
Modèles	Régression logistique (avec SMOTE) et arbre de décision, optimisés par GridSearch.
Résultat	Régression logistique : accuracy = 71 %, AUC = 0,705. Income seul : accuracy = 60 %. Un revenu faible est associé à plus de diabète.

Article 4 : Allani (2025)

Référence	Allani U. *Interactive Diabetes Risk Prediction Using Explainable Machine Learning: A Dash-Based Approach with SHAP, LIME, and Comorbidity Insights.* arXiv:2505.05683, 2025.
Données	BRFSS 2015 (Kaggle), environ 250 000 personnes.
Variable cible	Diabetes_012 transformée en binaire (prédiabétiques retirés).
Variables explicatives	Les 21 variables du dataset + 3 variables construites : - **Lifestyle Score** : PhysActivity, Fruits, Veggies, Smoker, HvyAlcoholConsump, MentHlth, PhysHlth - **Healthcare Access Score** : AnyHealthcare, NoDocbcCost - **Risk Factor Count** : HighBP + HighChol + Stroke + HeartDiseaseorAttack
Modèles	KNN, régression logistique, Random Forest, XGBoost, LightGBM, réseau de neurones (original, SMOTE, sous-échantillonnage).
Résultat	LightGBM + sous-échantillonnage : meilleur rappel (recall). Variables les plus importantes (SHAP) : Risk Factor Count, GenHlth, BMI.

Article 5 : Majcherek, Ciesielski & Sobczak (2025)

Référence	Majcherek D., Ciesielski A., Sobczak P. *AI-driven analysis of diabetes risk determinants in U.S. adults: Exploring disease prevalence and health factors.* PLoS One, 20(9), 2025.
Données	BRFSS 2015 (Kaggle), 253 680 personnes.
Variable cible	Diabetes_binary.
Variables explicatives (21)	HighBP, HighChol, CholCheck, BMI, Smoker, Stroke, HeartDiseaseorAttack, PhysActivity, Fruits, Veggies, HvyAlcoholConsump, AnyHealthcare, NoDocbcCost, GenHlth, MentHlth, PhysHlth, DiffWalk, Sex, Age, Education, Income
Modèles	18 modèles, dont Extra Trees, Random Forest, XGBoost, LightGBM, CatBoost, KNN et la régression logistique (rééquilibrage ROS, SMOTE, ADASYN).
Résultat	Extra Trees : accuracy = 96 %.

3. Tableau récapitulatif

Article	Année	Données	Nb de variables	Variables les plus importantes
Xie et al.	2019	BRFSS 2014	26	GenHlth, âge, IMC, revenu
Zhao	2023	BRFSS 2015 (Kaggle)	21	BMI, GenHlth, HighBP, HighChol, Age
Jafari Horestani & Owrang	2024	BRFSS 2015 (Kaggle)	21, puis 6	HighBP, HighChol, BMI, Income
Allani	2025	BRFSS 2015 (Kaggle)	21 + 3	Risk Factor Count, GenHlth, BMI
Majcherek et al.	2025	BRFSS 2015 (Kaggle)	21	Non précisé

4. Variables communes aux articles

Variable	Art. 1	Art. 2	Art. 3	Art. 4	Art. 5
BMI	X	X	X	X	X
GenHlth	X	X	X	X	X
Age	X	X	X	X	X
Income	X	X	X	X	X
Education	X	X	X	X	X
Sex	X	X	X	X	X
Smoker	X	X	X	X	X
PhysActivity	X	X	X	X	X
MentHlth	X	X	X	X	X
HeartDiseaseorAttack	X	X	X	X	X
AnyHealthcare	X	X	X	X	X
HighBP	-	X	X	X	X
HighChol	-	X	X	X	X
PhysHlth	-	X	X	X	X
Stroke, DiffWalk, Fruits, Veggies, HvyAlcoholConsump, NoDocbcCost, CholCheck	-	X	X	X	X
Sommeil, race, état civil, emploi, dépression	X	-	-	-	-

X = variable utilisée ; - = non utilisée. Pour l'article 1, les variables BRFSS 2014 équivalentes sont comptées (ex. X_BMI5CAT pour BMI).

5. Conclusion

Les cinq articles utilisent les données BRFSS du CDC, disponibles gratuitement en ligne. Quatre d'entre eux utilisent la version Kaggle 2015 avec 21 variables explicatives, comme notre projet. Les variables les plus souvent citées comme importantes sont **l'IMC (BMI), l'état de santé général (GenHlth), l'hypertension (HighBP), le cholestérol (HighChol) et l'âge**. La variable **PhysHlth**, étudiée dans notre étape 1, est utilisée dans quatre articles sur cinq. Elle est plus élevée chez les diabétiques, mais son effet devient faible quand les autres variables sont prises en compte (Zhao, 2023).

Références

[1] Xie Z. et al. (2019). Preventing Chronic Disease, 16. https://www.cdc.gov/Pcd/issues/2019/19_0109.htm

[2] Zhao Z. (2023). Highlights in Science, Engineering and Technology, 54. https://drpress.org/ojs/index.php/HSET/article/download/9805/9540/9596

[3] Jafari Horestani F., Owrang O M.M. (2024). arXiv:2404.13260. https://arxiv.org/abs/2404.13260

[4] Allani U. (2025). arXiv:2505.05683. https://arxiv.org/abs/2505.05683

[5] Majcherek D. et al. (2025). PLoS One, 20(9). https://pmc.ncbi.nlm.nih.gov/articles/PMC12407459/

[6] Dataset : https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset