PROJET DIABÈTE BRFSS · ANALYSE DES VARIABLES

Age et MentHlth

Deux variables pour décrire le profil d’âge et les jours de mauvaise santé mentale déclarés.

253 680 OBSERVATIONS

2 VARIABLES

BRFSS 2015

Mohammed Nezhari · Soufiane Ait ouchn · Abdelouafi Er-raqui

Encadré par Pr. Zineb BOUSBAA

Deux variables, deux lectures

Même échantillon : 253 680 répondants, sans valeur manquante sur ces deux colonnes.

AGE · TRANCHE D’ÂGE

Variable qualitative ordinale

Le fichier stocke l’âge sous forme de codes entiers de 1 à 13. Chaque code correspond à une tranche d’âge ; il ne s’agit pas d’un âge exact en années.

1	18-24 ans
2	25-29 ans
3	30-34 ans
4	35-39 ans
5	40-44 ans
6	45-49 ans
7	50-54 ans
8	55-59 ans
9	60-64 ans
10	65-69 ans
11	70-74 ans
12	75-79 ans
13	80 ans ou plus

MENTHLTH · JOURS DÉCLARÉS

Variable quantitative discrète

Nombre de jours, sur les 30 derniers jours, pendant lesquels la personne a déclaré que sa santé mentale n’était pas bonne.

0 à **30** jours possibles

- 0 jour signifie aucun jour de mauvaise santé mentale déclaré.
- 30 jours signifie que la personne en a déclaré pendant tout le mois.

À RETENIR Pour AGE, un code plus grand correspond à une tranche plus âgée ; pour MENTHLTH, un chiffre plus grand indique davantage de jours déclarés.

Les tranches 55-69 ans sont les plus représentées

La tranche la plus fréquente est 60-64 ans ; les 18-24 ans sont les moins représentés.

RÉPARTITION PAR TRANCHE D'ÂGE · FRÉQUENCE (%)



TRANCHE DOMINANTE

60-64 ans

13,10 % · 33 244 personnes

TRANCHE LA MOINS REPRÉSENTÉE

18-24 ans

2,25 % · 5 700 personnes

50 % CENTRAUX

45-69 ans

Q1 : 45-49 ans · médiane : 55-59 ans · Q3 : 65-69 ans

Une distribution légèrement asymétrique à gauche

Les statistiques doivent être lues en tenant compte du codage ordinal de la variable.

MOYENNE DES CODES

8,03

Proche du code 8 : 55-59 ans

MÉDIANE

8

55-59 ans

MODE

9

60-64 ans

ÉCART-TYPE

3,05

Dispersion des codes

FORME DE LA DISTRIBUTION

Skewness = -0,36

L’asymétrie est faible et orientée vers la gauche. La répartition est relativement équilibrée, avec une légère extension du côté des tranches les plus jeunes.

Kurtosis = -0,58

Excès de kurtosis négatif : distribution plus aplatie que la référence normale.

VALEURS EXTRÊMES ET DONNÉES

Aucun outlier détecté

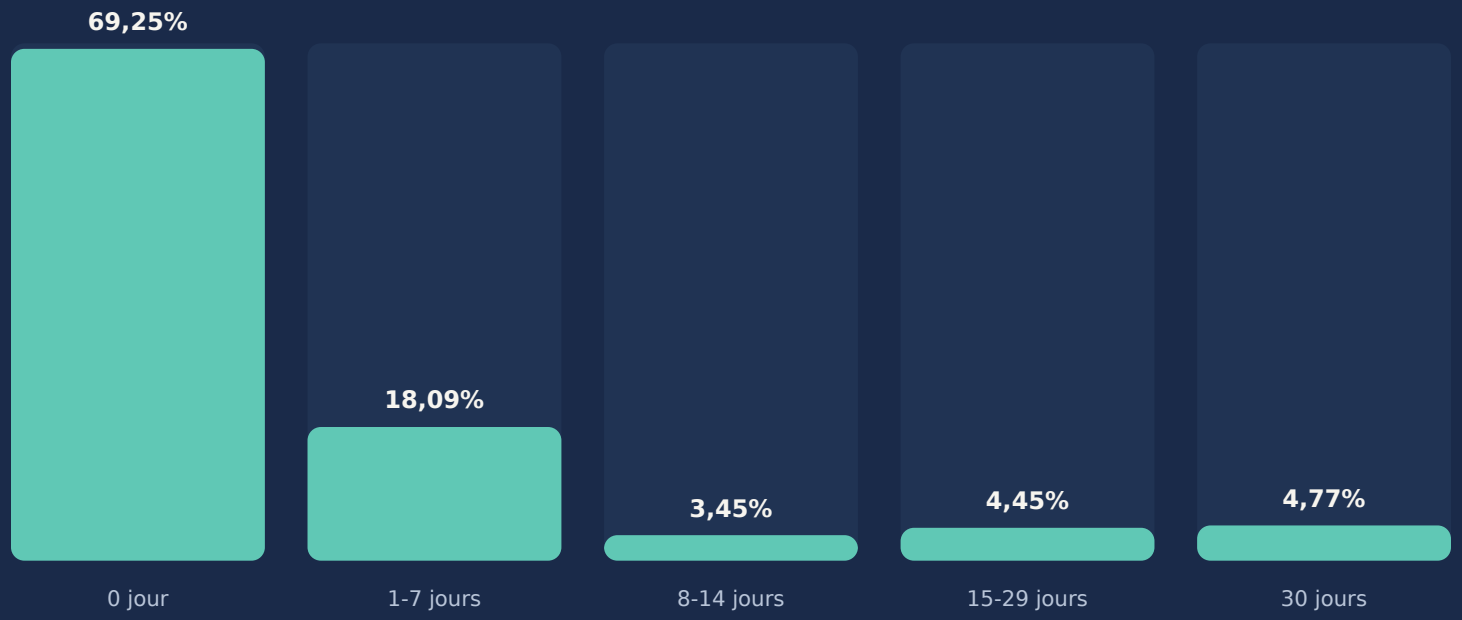
Q1 = code 6 (45-49 ans) · Q3 = code 10 (65-69 ans) · IQR = 4. Les bornes IQR sont 0 et 16 ; toutes les observations réelles sont comprises entre les codes 1 et 13.

Attention : la moyenne 8,03 et l’écart-type 3,05 portent sur les codes, pas sur des âges en années. La catégorie reste plus informative pour décrire le profil.

Près de 7 personnes sur 10 déclarent 0 jour

La fréquence des jours déclarés décroît fortement après la modalité 0.

RÉPARTITION EN CLASSES DE JOURS · FRÉQUENCE (%)



Modalité exacte la plus rare : 19 jours (16 réponses ; 0,006 %).

AUCUN JOUR DÉCLARÉ

69,25 %

175 680 personnes

MOYENNE

3,18 jours

Par personne sur les 30 derniers jours

30 JOURS DÉCLARÉS

4,77 %

12 088 personnes

Une distribution très asymétrique à droite

Quelques réponses élevées tirent la moyenne au-dessus de la médiane.

MÉDIANE / MODE

0 / 0

La modalité typique est 0 jour

ÉCART-TYPE

7,41

Dispersion importante

SKEWNESS

2,72

Forte asymétrie à droite

KURTOSIS

6,44

Queues plus importantes

QUARTILES ET ÉTENDUE

Q1 = 0 · Médiane = 0 · Q3 = 2

IQR = 2 · Minimum = 0 · Maximum = 30

La moitié centrale des observations se situe entre 0 et 2 jours. La moyenne est de 3,18 jours, supérieure à la médiane, car une minorité déclare davantage de jours.

VALEURS ATYPIQUES : DÉCISION

36 208 observations · 14,27 %

La règle IQR signale les valeurs supérieures à 5 jours (borne supérieure = 5 ; borne inférieure = -3). Mais 0 à 30 jours est l'intervalle valide : ces valeurs ne sont pas des erreurs.

Choix : ne pas supprimer les personnes. Appliquer log(1 + x) pour comprimer les grandes valeurs tout en conservant l'information.

APRÈS log(1 + x) Skewness : 1,52 (au lieu de 2,72) · Kurtosis : 0,95 (au lieu de 6,44) · Outliers IQR : 23,370 (9,21 %)

Nettoyer sans effacer les observations utiles

Aucune imputation nécessaire ; les transformations sont conservées dans de nouvelles colonnes.

ÉTAPE	AGE	MENTHLTH
Valeurs manquantes	Aucune (0)	Aucune (0)
Valeurs aberrantes	Aucune selon IQR	36 208 signalées (14,27 %) ; valeurs valides
Traitement	Conserver les codes 1 à 13	Créer MentHlth_log = log(1 + MentHlth)
Normalisation	Min-Max des codes : [0, 1]	Min-Max de MentHlth_log : [0, 1]

MIN-MAX

$$x_{norm} = (x - min) / (max - min)$$

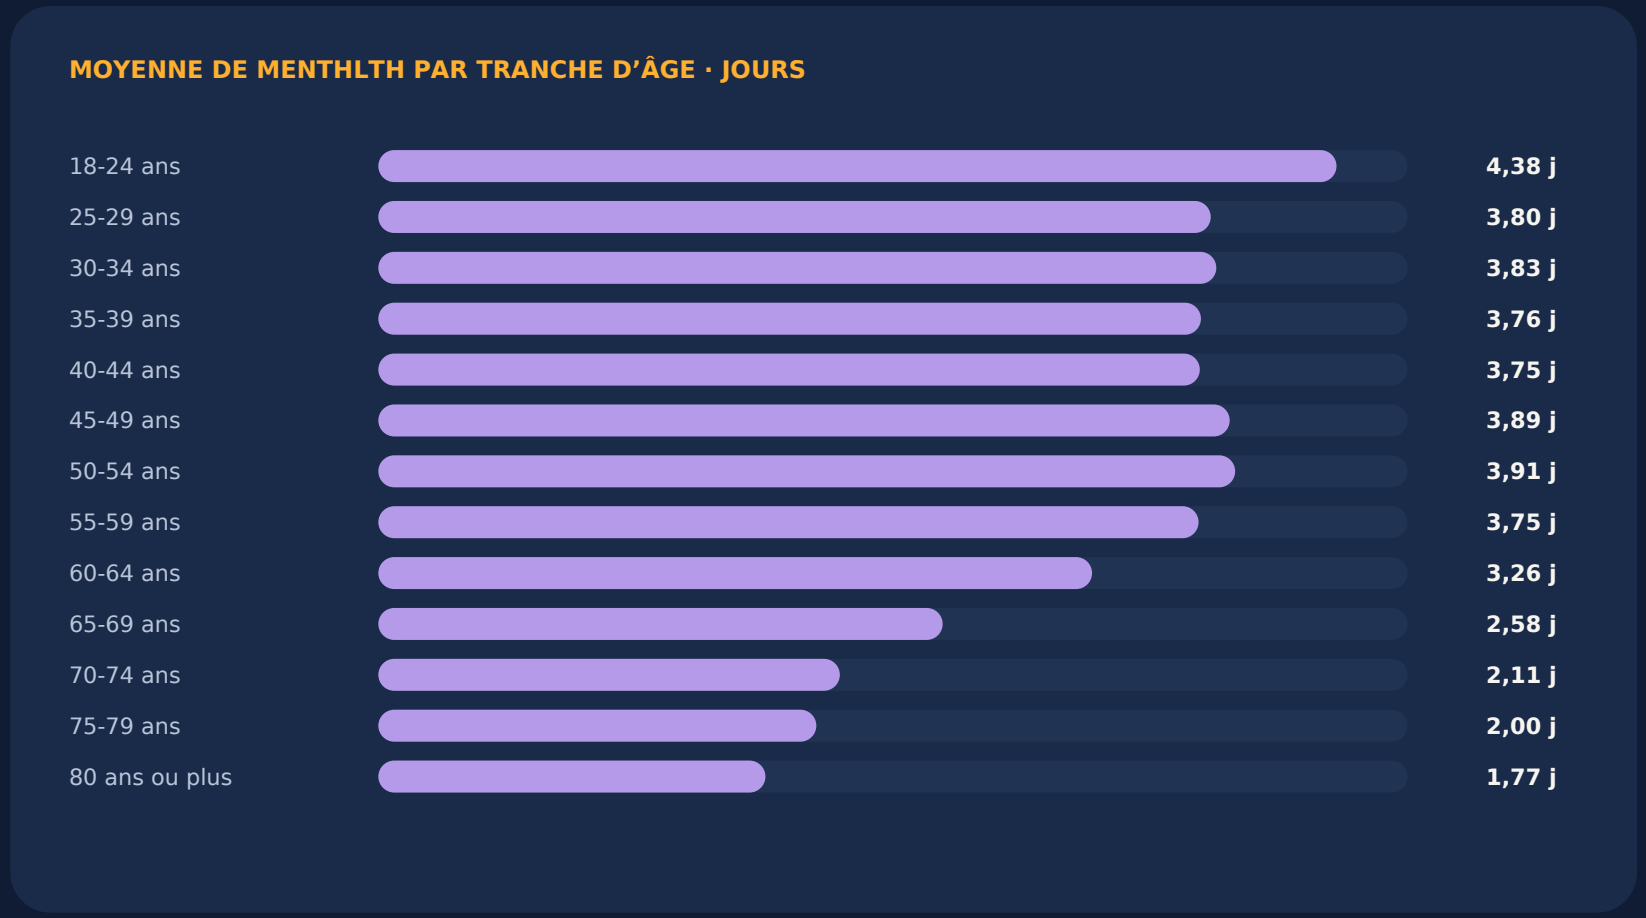
TRANSFORMATION MENTHLTH

$$x_{log} = \ln(1 + x)$$

Les colonnes originales sont conservées pour l’interprétation. Age est ordinale : sa normalisation met les codes sur une échelle commune, sans créer des âges exacts.

Les jours déclarés diminuent globalement avec l’âge

La moyenne de MentHlth tend à diminuer selon les tranches ; la médiane reste égale à 0 dans chaque groupe.



ASSOCIATION DE SPEARMAN

-0,164

Association négative faible

MOYENNE LA PLUS ÉLEVÉE

18-24 ans

4,38 jours

MOYENNE LA PLUS FAIBLE

80 ans ou plus

1,77 jour

À retenir

Les deux variables décrivent des aspects complémentaires de l’échantillon.

01 AGE

Profil d’âge

La tranche 60-64 ans est la plus représentée (13,10 %). Les 18-24 ans sont les moins nombreux (2,25 %).

02 MENTHLTH

Santé mentale déclarée

69,25 % déclarent 0 jour. La distribution est très asymétrique à droite ; la médiane et le mode valent 0.

03 TRAITEMENT

Préparation des données

Aucune valeur manquante. Les valeurs élevées de MentHlth sont conservées et comprimées par log(1+x).

CONCLUSION GÉNÉRALE

L’échantillon est davantage représenté par les adultes de 55 à 69 ans. Pour MentHlth, la majorité ne déclare aucun jour de mauvaise santé mentale, mais une minorité rapporte des durées élevées. La transformation logarithmique réduit l’asymétrie sans supprimer ces observations. L’analyse croisée montre une association négative faible entre le code d’âge et le nombre de jours déclarés ; elle ne permet pas de conclure à une causalité.

Source : fichier diabetes_012_health_indicators_BRFSS2015.csv · calculs descriptifs sur 253 680 observations. Les valeurs sont arrondies pour la présentation.